

Análisis Exploratorio de Datos (EDA):

**Relación entre Indicadores Socioeconómicos y el
Riesgo de Extinción Lingüística**

Melania Fondevilla

Maria Rodriguez

William Walker

Contenido

Introducción.....	1
Hipótesis y plan de acción.....	2
H1: Grado de desaparición y región.....	2
H2: Variabilidad por región.....	2
H3: Grado de desaparición y número de hablantes.....	2
H4: Densidad de población y número de lenguas en peligro de desaparición.....	3
H5: Grado de desaparición y PIB.....	4
H6: Grado de desaparición y alfabetización.....	4
Análisis exploratorio.....	4
Descripción de los datasets y preparación de los datasets.....	4
Dataset de lenguas.....	5
Dataset socioeconómico países.....	6
Integración de ambos datasets.....	6
Limitaciones iniciales.....	6
Análisis exploratorio del dataset combinado.....	7
Visualizaciones.....	8
Conclusiones.....	8
Recomendaciones.....	8
Anexos.....	8
Código de limpieza.....	9
Tablas auxiliares.....	10
Diccionario de equivalencias de países.....	10
Fuentes y bibliografía.....	11

Introducción

En este EDA se analiza el fenómeno de la desaparición de lenguas y su relación con las desigualdades socioeconómicas entre países. Muchas lenguas minoritarias, especialmente aquellas con comunidades de hablantes reducidas, presentan un mayor riesgo de extinción. Paralelamente, factores socioeconómicos como el nivel de desarrollo, la alfabetización o la estabilidad demográfica influyen en la capacidad de las comunidades para preservar su identidad cultural y lingüística.

Este enfoque se apoya en los criterios de vitalidad lingüística establecidos por UNESCO (2003), especialmente los relacionados con la transmisión intergeneracional, los cambios en los dominios de uso y las actitudes de la comunidad hacia su propia lengua.

Para estudiar esta posible relación, se emplean dos datasets complementarios: **Countries of the World**, que recoge indicadores socioeconómicos por país, y **Extinct Languages**, que clasifica lenguas minoritarias según su nivel de riesgo.

El objetivo de este EDA es explorar patrones, visualizar distribuciones y evaluar si existe una asociación entre el desarrollo socioeconómico de un país y el grado de amenaza de sus lenguas.

Hipótesis y plan de acción

Para evaluar la posible relación entre el nivel socioeconómico y el riesgo de desaparición lingüística, se plantean las siguientes hipótesis de trabajo. Cada una se analiza mediante técnicas estadísticas adecuadas al tipo de variables implicadas.

Este planteamiento implica la posible relación entre dos aspectos:

- El nivel socioeconómico de un país (medible gracias a indicadores como el PIB per cápita, alfabetización, mortalidad infantil, esperanza de vida, etc.)
- Situación de lenguas minoritarias o vulnerables.

Para estudiar esta posible relación entre el desarrollo socioeconómico y el grado de desaparición de lenguas de un país, estudiaremos las siguientes hipótesis:

H1: Grado de desaparición y región.

Se plantea la hipótesis de que la distribución del grado de peligro lingüístico no es homogénea entre las distintas regiones del mundo. En concreto, se espera que las regiones de Asia-Pacífico y América concentren una mayor proporción de lenguas en estados críticos de desaparición en comparación con Europa.

Estas diferencias podrían explicarse por factores como la elevada diversidad lingüística presente en determinadas zonas, la existencia de numerosas lenguas indígenas y minoritarias, así como distintos procesos históricos y socioculturales que han afectado de forma desigual a la preservación de las lenguas.

Para evaluar esta hipótesis se analizará la relación entre la variable Región, de tipo categórica nominal, y el Grado de peligro de desaparición, variable categórica ordinal tratada como categórica. El análisis se realizará mediante un Test Chi-Cuadrado de independencia, que permitirá estudiar si existe asociación entre ambas variables.

A partir de este procedimiento se obtendrán una tabla de contingencia, las frecuencias observadas y esperadas y el correspondiente p-value, elementos que permitirán determinar si las diferencias observadas entre regiones son estadísticamente significativas.

H2: Variabilidad por región.

Se plantea la hipótesis de que la variabilidad en el número de hablantes de las lenguas en peligro no es homogénea entre regiones, sino que existen diferencias significativas en su dispersión. En particular, se espera que Asia presente una mayor variabilidad que Europa, debido a la coexistencia de lenguas con un elevado número de hablantes junto a otras prácticamente extinguidas.

Esta diferencia podría estar relacionada con factores como la elevada diversidad lingüística y demográfica de algunos países asiáticos, donde conviven grandes lenguas regionales con numerosas lenguas minoritarias o indígenas. Por el contrario, en Europa se espera una distribución más homogénea en el número de hablantes de las lenguas en peligro.

Para evaluar esta hipótesis se analizará la dispersión de los datos mediante boxplots y el cálculo del rango intercuartílico (IQR) por región.

H3: Grado de desaparición y número de hablantes

Hipótesis: Las lenguas con un mayor número de hablantes presentan un menor riesgo de desaparición.

Esta hipótesis plantea una relación inversa entre el tamaño de la comunidad lingüística y el grado de amenaza. Para evaluarla, se analiza la asociación entre dos variables:

- **Número de hablantes** (*number_of_speakers*), una variable numérica continua con distribución altamente sesgada.
- **Grado de peligro de desaparición** (*endangerment_score*), una variable ordinal transformada en rangos.

H4: Densidad de población y número de lenguas en peligro

Hipótesis: Los países con mayor densidad de población no presentan necesariamente un mayor número de lenguas en peligro de desaparición.

Esta hipótesis implica una relación lineal entre:

- **Densidad de población** (*Pop_density*), variable numérica continua.
- **Número de lenguas en peligro por país**, obtenido tras agrupar el dataset lingüístico por país y contabilizar cuántas lenguas amenazadas se registran en cada territorio.

H5: Grado de desaparición y PIB

Se plantea la hipótesis de que los países con mayor PIB per cápita presentan, de media, lenguas con un menor grado de peligro de desaparición. Esta relación se fundamenta en la idea de que un mayor desarrollo económico puede favorecer la implementación de políticas de preservación lingüísticas, la educación bilingüe y la documentación de lenguas minoritarias.

Sin embargo, cabe considerar el efecto contrario: el crecimiento económico también se asocia históricamente con procesos de urbanización e integración que tienden a homogeneizar las lenguas habladas, acelerando el abandono de las lenguas locales.

Para evaluar esta hipótesis se analizará la relación entre la variable **PIB per cápita**, de tipo numérica continua, y el **endangerment_score**, variable ordinal codificada numéricamente en una escala del 1 al 5. Dado que ambas variables presentan distribuciones asimétricas con valores extremos, y que los grupos no cumplen el supuesto de normalidad (verificado mediante el test de Shapiro-Wilk), se descarta el uso de ANOVA y se aplica el test de Kruskal-Wallis como alternativa no paramétrica equivalente.

Para ello, el PIB per cápita se dividirá en cuartiles, permitiendo comparar el score de peligro medio entre países de distinto nivel económico. En caso de obtener diferencias estadísticamente significativas, se aplicará el test post-hoc de Dunn con corrección de Bonferroni para identificar entre qué grupos concretos se producen dichas diferencias.

A partir de este procedimiento se obtendrán el estadístico H de Kruskal-Wallis, el p-value asociado y, si procede, la matriz de comparaciones por pares del test de Dunn, elementos que nos permitirán determinar si el nivel de desarrollo económico de un país se asocia de forma significativa con el grado de peligro de sus lenguas.

H6: Grado de desaparición y alfabetización

Se plantea la hipótesis de que los países con mayor tasa de alfabetización presentan lenguas con un menor grado de peligro de desaparición. Esta relación se fundamenta en la idea de que sistemas educativos más desarrollados pueden favorecer la inclusión de lenguas minoritarias en la enseñanza, retrasando su proceso de extinción.

Para evaluar esta hipótesis se analizará la relación entre la variable **tasa de alfabetización**, de tipo numérica continua, y el **endangerment_score**, variable ordinal codificada numéricamente en una escala del 1 al 5. Al igual que en la hipótesis anterior, dado que los datos no cumplen el supuesto de normalidad (verificado mediante el test de Shapiro-Wilk), se aplica el test de Kruskal-Wallis como alternativa no paramétrica.

Para ello, la tasa de alfabetización se dividirá en cuartiles, permitiendo comparar el score de peligro entre países con distintos niveles educativos. En caso de obtener diferencias estadísticamente significativas, se aplicará el test post-hoc de Dunn con corrección de Bonferroni para identificar entre qué grupos concretos se producen dichas diferencias.

A partir de este procedimiento se obtendrán el estadístico H de Kruskal-Wallis, el p-value asociado y, si procede, la matriz de comparaciones por pares del test de Dunn, elementos que permitirán determinar si el nivel educativo de un país se asocia de forma significativa con el grado de peligro de sus lenguas.

Análisis exploratorio

Descripción y preparación de los datasets

Para este estudio se emplean dos fuentes de datos complementarias:

- **Extinct Languages** (The Guardian, 2017), que recoge información sobre lenguas minoritarias y su grado de riesgo.
- **Countries of the World** (Lasso, 2018), que contiene indicadores socioeconómicos por país.

Ambos datasets permiten abordar el fenómeno desde dos perspectivas: la vitalidad lingüística y el contexto socioeconómico de los países donde se hablan estas lenguas.

Dataset de lenguas

El dataset Extinct Languages contiene 2.722 lenguas y 15 variables, con la lengua como unidad de análisis. Incluye información sobre:

- **Variables categóricas:** nombre de la lengua, país o países donde se habla, códigos ISO, grado de peligro, nombres alternativos.
- **Variables numéricas:** número de hablantes, coordenadas geográficas.
- **Variables geográficas:** país y región.

El análisis preliminar muestra una distribución altamente asimétrica en el número de hablantes: la mayoría de lenguas tienen comunidades muy pequeñas, mientras que unas pocas concentran millones de hablantes. Por ello, se emplean medidas robustas como la **mediana** y se consideran transformaciones no paramétricas en los análisis posteriores.

Limpieza y preprocesamiento de datos:

Eliminación y normalización de columnas:

Se eliminan las columnas "Name in French", "Name in Spanish", "Country codes alpha 3", "ISO639-3 codes", "Alternate names", "Name in the language", "Sources", "Latitude" y "Longitude" debido a su bajo o nulo peso dentro del análisis realizado. Además, se llevó a cabo la normalización de los nombres de las columnas

utilizando el formato `snake_case` con el objetivo de mantener una estructura homogénea y facilitar el tratamiento posterior de los datos.

Endangerment Score:

Categorización de la columna “Degree of endangerment” en una nueva columna denominada “`endangerment_score`”, asignando valores numéricos del 1 al 5 según el grado de peligro de extinción, donde 1 representa el menor nivel de peligro y 5 el mayor. Esta transformación permite aplicar técnicas estadísticas que requieren variables ordinales o numéricas.

Number of speakers:

El tratamiento de los valores nulos en la columna Number of speakers se ha realizado teniendo en cuenta el contexto de las lenguas afectadas. La mayoría de las lenguas cuyo número de hablantes aparece como NaN se localizan en países extensos, con alta población y una gran diversidad lingüística, donde es frecuente la existencia de lenguas indígenas o minoritarias con escasa documentación. Aproximadamente la mitad de estas lenguas no tienen fuentes (Source) asociadas y presentan muy poca o ninguna información disponible sobre su número de hablantes.

Dado que el conjunto de lenguas con valor nulo en esta variable representa únicamente alrededor del 6% del total de registros, se ha decidido eliminar dichas lenguas del análisis, considerando que la ausencia de información dificulta su tratamiento y que su impacto sobre el conjunto global de datos es reducido, además de la imposibilidad de imputar valores fiables.

Dataset socioeconómico países

El dataset *Countries of the World* contiene **227 países** y **20 variables**, con indicadores como PIB per cápita, alfabetización, mortalidad infantil, densidad de población o estructura económica.

Incluye:

- **Variables numéricas continuas:** población, área, densidad, PIB per cápita, alfabetización, mortalidad infantil, tasas de natalidad y mortalidad, etc.
- **Variables categóricas:** país, región, clima.

Limpieza y preprocesamiento de datos:

Limpieza y normalización del formato de datos y columnas

- Eliminación de espacios en blanco en los nombres de las columnas.
- Estandarización de los nombres de columnas utilizando el formato `snake_case`.
- Verificación y corrección del formato de los separadores decimales, sustituyendo comas por puntos en aquellos casos necesarios.
- Conversión de tipos de datos para optimizar el tratamiento de la información.
- Transformación de las variables “Country”, “Region” y “Climate” al tipo categórico (category), al tratarse de variables cualitativas codificadas.

Tratamiento de valores nulos y limpieza de datos

- Identificación de columnas con presencia de valores nulos (NaN).
- Evaluación de distintas estrategias de tratamiento según el tipo de variable y el porcentaje de valores ausentes.
- Imputación mediante media o mediana en variables numéricas cuando resulta adecuado.
- Imputación mediante la moda en variables categóricas.

- Eliminación de filas en aquellos casos donde el porcentaje de valores nulos era reducido y no comprometía la representatividad del conjunto de datos.
- Documentación de las decisiones tomadas durante el proceso para garantizar la reproducibilidad y trazabilidad del análisis.

Integración de ambos datasets

La combinación de los datasets requirió un proceso cuidadoso debido a que una lengua puede estar asociada a varios países.

Las operaciones realizadas fueron:

1. **Limpieza y división de la columna *countries*** en el dataset lingüístico, transformándola en listas.
2. **Explode**: cada país asociado a una lengua se convirtió en una fila independiente.
3. Normalización de nombres de países (espacios, capitalización, equivalencias).
4. Preparación equivalente en el dataset socioeconómico para asegurar coincidencia exacta.
5. **Merge** entre ambos datasets.
6. Diagnóstico final para identificar lenguas sin correspondencia de país.

Este proceso permitió obtener un dataset combinado donde cada lengua está asociada a los indicadores socioeconómicos del país donde se habla.

Limitaciones iniciales

El proceso de integración y análisis de los dos datasets presentó varias limitaciones que fue necesario abordar antes de realizar los análisis estadísticos:

- **Limpieza y estandarización de datos**: ambos datasets contenían inconsistencias en nombres de países, formatos numéricos y presencia de valores nulos que requirieron un preprocesado exhaustivo.
- **Normalización de nombres de países**: la variable *Countries* del dataset lingüístico incluía múltiples formatos, variantes ortográficas y listas de países por lengua, lo que dificultaba el cruce con el dataset socioeconómico.
- **Lenguas asociadas a múltiples países**: una misma lengua puede aparecer en varios territorios, lo que obligó a expandir la columna *Countries* y a redefinir la unidad de análisis en el dataset combinado.
- **Selección de variables relevantes**: fue necesario filtrar columnas con escasa utilidad analítica para evitar ruido y facilitar la interpretación de los resultados.
- **Merge entre datasets**: la integración final requirió resolver discrepancias entre nombres de países, eliminar casos sin correspondencia y verificar la consistencia del dataset resultante.

Estas limitaciones no invalidan el análisis, pero sí condicionan la interpretación de los resultados y justifican algunas de las decisiones metodológicas adoptadas.

Análisis exploratorio del dataset combinado

H1. Grado de desaparición y región

Heatmap - Distribución del grado de peligro por región:

El heatmap permite observar diferencias claras en la distribución del grado de peligro de las lenguas según la región analizada. En regiones como Asia (excepto Oriente Próximo), Bálticos, Comunidad de Estados

Independientes, Europa del Este, Latinoamérica y Caribe, Europa Occidental y Oriente Próximo, la mayor proporción de lenguas se concentra en categorías de peligro inferiores, especialmente en los niveles “Vulnerable” y “Definitely endangered”. Además, en estas regiones los porcentajes asociados a las categorías más cercanas a la extinción son relativamente reducidos.

Por el contrario, en regiones como Norteamérica, Norte de África, África Subsahariana y Oceanía se observa una mayor concentración de lenguas en categorías de peligro más elevadas. En estas regiones, la categoría “Critically endangered” presenta los porcentajes más altos dentro de cada distribución regional, lo que sugiere una situación de mayor riesgo para las lenguas minoritarias.

Estos resultados podrían estar relacionados con procesos de homogeneización lingüística, donde las lenguas dominantes o mayoritarias adquieren un peso cada vez mayor frente a lenguas locales o secundarias, favoreciendo así la pérdida progresiva de estas últimas y aumentando su cercanía a la extinción.

Test Chi-Cuadrado (Chi2 Contingency). Región - Grado de peligro:

Los resultados obtenidos en el Test Chi-Cuadrado permiten rechazar claramente la hipótesis nula de independencia, dado que el p-valor obtenido es extremadamente reducido y próximo a 0. Esto indica que existe una relación estadísticamente significativa entre la región geográfica y el grado de peligro de extinción de las lenguas registradas en dichas regiones.

Además, el elevado valor del estadístico Chi-Cuadrado refleja que las diferencias entre las frecuencias observadas y las frecuencias esperadas bajo el supuesto de independencia son considerables. Esto sugiere que la distribución del grado de peligro no se produce de manera homogénea entre regiones, sino que determinadas regiones presentan patrones claramente diferenciados.

Los resultados observados en el heatmap respaldan esta conclusión, ya que regiones como Norteamérica, Oceanía, África Subsahariana o Norte de África presentan una mayor concentración de lenguas en categorías críticas de peligro, mientras que otras regiones concentran una mayor proporción de lenguas en categorías de riesgo más moderado.

Aunque el test confirma la existencia de relación entre ambas variables, no permite establecer causalidad directa, sino únicamente asociación estadística entre la región y el nivel de peligro de extinción de las lenguas.

H2. Variabilidad por región

El boxplot en escala logarítmica permite observar la distribución del número de hablantes de las lenguas en peligro según la región geográfica, mientras que el stripplot complementa la representación mostrando la dispersión individual de los registros. De forma general, se aprecia una elevada heterogeneidad entre regiones, existiendo diferencias notables tanto en la mediana como en la amplitud de las distribuciones.

Visualmente, regiones como Asia (excepto Oriente Próximo) presentan una gran dispersión y una elevada concentración de registros distribuidos a lo largo de prácticamente toda la escala, lo que indica la coexistencia de lenguas con muy pocos hablantes junto a otras con comunidades lingüísticas considerablemente mayores. Sin embargo, el cálculo del rango intercuartílico (IQR) muestra que Europa del Este y Europa Occidental presentan una variabilidad aún mayor dentro del 50% central de la distribución.

En concreto, Europa del Este (3.475.000) y Europa Occidental (970.000) obtienen algunos de los valores de IQR más elevados del conjunto analizado, junto con la región de los Bálticos (3.450.000). Esto refleja una diferencia especialmente pronunciada entre lenguas con menor y mayor número de hablantes dentro de dichas regiones. Por el contrario, aunque Asia presenta una gran amplitud total y numerosos valores extremos, su IQR es considerablemente inferior (19.700), indicando que la parte central de la distribución se encuentra más concentrada.

Estos resultados sugieren que la percepción visual de una mayor dispersión en Asia está fuertemente influida por la presencia de valores extremos y por el elevado número de registros presentes en la región. En cambio, el IQR permite analizar específicamente la variabilidad de la zona central de los datos, mostrando que la heterogeneidad interna es mayor en las regiones europeas.

H3. Grado de desaparición y número de hablantes

Tal como se planteó en el enunciado de la hipótesis, el análisis se centra en la relación entre el número de hablantes (*number_of_speakers*) y el grado de peligro de desaparición (*endangerment_score*). Dado que *endangerment_score* es una variable ordinal y que la distribución del número de hablantes presenta una marcada no normalidad —como se observa en el histograma de la Fig. 3-1, donde la fuerte concentración de lenguas en los rangos inferiores y la larga cola hacia la derecha evidencian una asimetría extrema— no es adecuado asumir una relación lineal entre ambas variables.

Por este motivo se emplea el coeficiente de correlación de **Spearman**, apropiado para detectar relaciones monotónicas en variables que no siguen una distribución normal. Recordemos que Spearman evalúa si existe una tendencia creciente o decreciente entre dos variables, independientemente de que la relación sea lineal, siempre que mantenga un orden consistente.

El coeficiente obtenido para esta hipótesis es $\rho = -0.699$, con un **p-value = 0.000e+00**. Este valor negativo indica una **relación monotónica inversa**: a medida que disminuye el número de hablantes, aumenta el nivel de amenaza. La magnitud del coeficiente (cercana a -0.7) sugiere una asociación fuerte entre ambas variables.

El p-value prácticamente igual a cero confirma que esta relación es **estadísticamente significativa**, es decir, altamente improbable bajo la hipótesis nula de ausencia de asociación. En conjunto, estos resultados respaldan la hipótesis planteada: **las lenguas con más hablantes tienden a presentar niveles más bajos de peligro de desaparición**.

H4. Densidad de población y número de lenguas en peligro

Tal como se planteó en el enunciado de la hipótesis, el análisis se centra en la relación entre la densidad de población (*Pop_density*) —variable numérica continua— y el número de lenguas en peligro por país (*num_endangered_languages*). Para obtener esta última variable fue necesario transformar el dataset lingüístico a nivel territorial. Para ello se construyó la tabla auxiliar *df_country_counts*, que agrupa las lenguas por país y contabiliza cuántas de ellas se encuentran en situación de amenaza. Esta agregación permitió generar una variable numérica comparable entre países. Posteriormente, esta tabla se integró con el dataset de países mediante un *merge* por la columna *Countries_list*, obteniendo un dataframe final adecuado para el análisis correlacional.

Antes de aplicar el coeficiente de Pearson, se realizó un tratamiento de valores faltantes en la variable *Pop_density*. Se identificaron países sin datos de densidad de población y se completaron los valores cuando existían fuentes oficiales (Montenegro y Costa de Marfil). Los casos sin información fiable (Niue, Tokelau, Norfolk Island y Pitcairn) fueron descartados para evitar sesgos en el análisis.

Una vez preparado el dataset, se aplicó el coeficiente de correlación de Pearson, adecuado para evaluar relaciones lineales entre dos variables numéricas continuas. En este caso, el coeficiente obtenido fue $r = 0.0587$, con un **p-value = 0.00187**. Aunque el p-valor indica significación estadística —debida principalmente al tamaño de la muestra— la magnitud del coeficiente es extremadamente baja, lo que implica que la relación carece de relevancia práctica. En otras palabras, la densidad de población no explica el número de lenguas en peligro presentes en un país.

Esta ausencia de relación se aprecia también en la visualización tipo *bubble chart* (Fig. 4), donde no se observa ningún patrón lineal ni tendencia clara entre ambas variables. Además, destaca el caso de Europa, que pese a ser la región más densamente poblada, presenta un número muy reducido de lenguas en riesgo, actuando como un outlier conceptual respecto a la hipótesis de partida.

Dado que la variable *Pop_density* presenta valores extremadamente heterogéneos —con países muy densos que actúan como outliers— se aplicó una escala logarítmica para mejorar la interpretación visual. No obstante, incluso tras esta transformación, no se observa ninguna estructura que sugiera una relación lineal entre densidad de población y número de lenguas amenazadas.

En conjunto, los resultados estadísticos y visuales apoyan la hipótesis planteada: **los países más densamente poblados no presentan necesariamente un mayor número de lenguas en peligro.**

H5. Grado de desaparición y PIB

El análisis exploratorio muestra que la relación entre el PIB per cápita y el grado de peligro de desaparición lingüística es muy débil. El coeficiente de correlación de Spearman obtenido ($p = 0.071$) refleja una asociación positiva prácticamente inexistente entre ambas variables, indicando que un mayor nivel de desarrollo económico no implica necesariamente una menor amenaza para las lenguas presentes en un país.

No obstante, el p-value asociado (0.0002) resulta estadísticamente significativo. Este resultado debe interpretarse con cautela, ya que el elevado tamaño muestral del conjunto de datos permite detectar como significativas incluso relaciones muy pequeñas. Por tanto, aunque existe evidencia estadística de asociación, el efecto observado carece de relevancia práctica y no permite afirmar que el PIB per cápita actúe como un factor claramente protector frente a la desaparición lingüística.

El análisis mediante Kruskal-Wallis y el posterior test post-hoc de Dunn permiten profundizar en estas diferencias entre grupos económicos. Los resultados muestran que los países pertenecientes al cuartil de menor PIB per cápita presentan diferencias significativas respecto al resto de grupos, mientras que entre los cuartiles intermedios y altos las diferencias son mucho menos pronunciadas. Esto sugiere que la relación entre desarrollo económico y peligro lingüístico no sigue un patrón lineal simple.

H6. Grado de desaparición y alfabetización

El análisis exploratorio muestra una relación extremadamente débil entre la tasa de alfabetización y el grado de peligro de desaparición lingüística. El coeficiente de correlación de Spearman obtenido ($p = 0.071$) indica una asociación positiva prácticamente inexistente entre ambas variables, lo que sugiere que niveles más altos de alfabetización no se traducen necesariamente en una menor amenaza para las lenguas minoritarias.

La representación gráfica de los datos confirma esta ausencia de patrón claro. Aunque puede apreciarse una ligera tendencia creciente, la dispersión de los registros es muy elevada en todos los niveles de alfabetización, observándose lenguas en todos los grados de peligro tanto en países con baja como con alta alfabetización. Esto evidencia una importante heterogeneidad interna y dificulta establecer una relación consistente entre ambas variables.

El análisis mediante Kruskal-Wallis y el posterior test post-hoc de Dunn muestran que únicamente existen diferencias estadísticamente significativas entre el cuartil de menor alfabetización (Q1) y el cuartil medio-alto (Q3). Sin embargo, no se observa una progresión gradual entre el resto de grupos, ya que las comparaciones restantes no presentan diferencias significativas. Estos resultados indican que la alfabetización no actúa como un predictor lineal del grado de peligro lingüístico.

Visualizaciones




Fig 1. Heatmap. Distribución grado de peligro por región.




Fig 2. Boxplot & Stripplot. Distribución del número de hablantes por región.




Fig 3-1. Histograma. Distribución fuertemente asimétrica de la distribución del número de hablantes.




Fig 3-2. Scatterplot - Análisis bivalente entre número de hablantes y riesgo de desaparición de una lengua.




Fig 4. Bubble Chart. Análisis bivalente de la densidad de población y riesgo de desaparición de una lengua.




Fig 5-1. Boxplot. Score de peligro por cuartil de PIB per cápita.




Fig 5-2. Scatterplot. PIB per cápita vs. grado de peligro de extinción.




Fig 5-3. Heatmap. P-valores post-hoc Dunn por cuartiles de PIB.




Fig 6-1. Histograma. Distribución de la tasa de alfabetización por países.




Fig 6-2. Scatterplot. Tasa de alfabetización vs. grado de peligro de extinción.




Fig 6-3. Boxplot. Score de peligro por cuartil de alfabetización.




Fig 6-4. Heatmap. P-valores post-hoc Dunn por cuartiles de alfabetización.

Conclusiones

H1. Grado de desaparición y región

La hipótesis planteada queda **parcialmente confirmada**. Aunque se esperaba encontrar una mayor concentración de lenguas críticamente en peligro en Asia-Pacífico y América respecto a Europa, los resultados muestran una distribución del riesgo lingüístico más heterogénea de lo inicialmente previsto. Si bien algunas regiones de América y Oceanía presentan una elevada proporción de lenguas en estados críticos, otras zonas asiáticas y europeas concentran principalmente niveles de peligro moderado. Por tanto, puede afirmarse que el grado de peligro lingüístico varía significativamente según la región del mundo, aunque los patrones observados no coinciden completamente con lo planteado en la hipótesis inicial.

H2. Variabilidad por región

La hipótesis planteada queda solo **parcialmente respaldada**. Si bien Asia concentra lenguas con cantidades de hablantes muy dispares, incluyendo tanto lenguas con miles de hablantes como otras cercanas a la extinción, la variabilidad observada en los valores centrales de la distribución no resulta superior a la de las regiones europeas. Por tanto, los resultados muestran que la elevada dispersión asiática está influida principalmente por la presencia de valores extremos, mientras que en Europa la variabilidad interna del conjunto de datos es más consistente.

H3 - H4. Grado de desaparición y número de hablantes - Densidad de población y número de lenguas en peligro de desaparición

Respecto a las hipótesis de **carácter demográfico** (H3 y H4) podemos indicar claramente que las lenguas con comunidades más reducidas de hablantes tienen a presentar niveles más altos de amenaza, evidenciando que el número de habitantes es un factor importante en la vitalidad lingüística.

Por otro lado, respecto a la densidad de población no se aprecia un patrón claro que relacione la densidad con el número de lenguas en peligro, siendo un caso destacado el de Europa que, pese a su alta densidad poblacional, presenta un número muy reducido de lenguas amenazadas.

H5. Grado de desaparición y PIB

La hipótesis planteada queda **rechazada en su formulación original**. Los resultados obtenidos no permiten afirmar que un mayor PIB per cápita se asocie de forma clara con un menor grado de peligro de desaparición lingüística. La correlación observada es prácticamente inexistente, lo que indica que el desarrollo económico, por sí solo, no explica adecuadamente el nivel de amenaza de las lenguas.

Sin embargo, los análisis realizados sí evidencian diferencias significativas en los países con menores niveles de renta, cuyos valores difieren respecto al resto de grupos económicos. Esto sugiere la posible existencia de un umbral mínimo de desarrollo económico por debajo del cual las lenguas presentan una mayor vulnerabilidad, aunque dicha relación no se mantiene de forma proporcional en niveles económicos superiores.

H6. Grado de desaparición y alfabetización

La hipótesis planteada queda **rechazada**. Los resultados obtenidos no permiten afirmar que una mayor tasa de alfabetización se asocie de forma consistente con un menor grado de peligro de desaparición lingüística. La correlación observada es prácticamente inexistente y las diferencias detectadas entre grupos no siguen una tendencia progresiva clara.

Aunque el análisis post-hoc identifica diferencias significativas entre algunos niveles concretos de alfabetización, estas no resultan suficientes para sostener la existencia de una relación sólida entre educación y preservación lingüística. Por tanto, la alfabetización, considerada de forma aislada, no explica adecuadamente el nivel de amenaza de las lenguas.

Conclusión general

El análisis realizado muestra que la desaparición lingüística es un fenómeno complejo en el que pueden intervenir factores geográficos, demográficos y socioeconómicos, aunque no todos ellos presentan patrones claros o consistentes. Desde una perspectiva territorial, se observa que América y Oceanía concentran una mayor proporción de lenguas en peligro, mientras que Europa presenta niveles de amenaza notablemente más bajos. No obstante, la distribución del riesgo dentro de cada región es heterogénea y no siempre responde a los patrones esperados inicialmente.

En el plano demográfico, los resultados son más concluyentes: las lenguas habladas por comunidades pequeñas tienden a presentar mayores niveles de amenaza, lo que confirma la importancia del tamaño poblacional como factor de vulnerabilidad lingüística. Sin embargo, los indicadores socioeconómicos analizados —PIB per cápita y tasa de alfabetización— no muestran una relación sólida con el grado de peligro. Aunque los países con menor renta presentan una mayor concentración de lenguas amenazadas, esta relación no se mantiene de forma lineal en niveles económicos más altos, y la alfabetización tampoco ofrece un patrón claro que permita explicar la vitalidad lingüística. En conjunto, los resultados sugieren que la desaparición de lenguas no puede atribuirse a un único factor, sino que responde a una combinación de dinámicas culturales, históricas y sociales que requieren un análisis más profundo.

Recomendaciones

En este estudio se ha trabajado a nivel de país, lo que permite una visión global, pero también puede enmascarar otros resultados.

Un análisis más granular —por regiones dentro de un mismo país, por comunidades lingüísticas específicas o incluso por variables socioculturales adicionales— podría ofrecer una imagen más fiel de la diversidad y complejidad lingüística de cada territorio.

También sería interesante incorporar nuevas fuentes de información que permitan evaluar factores no incluidos en este EDA, como políticas lingüísticas, procesos históricos de desplazamiento cultural, migraciones internas o la presencia de programas de revitalización.

La combinación de indicadores demográficos, socioeconómicos y culturales a diferentes escalas territoriales podría ayudar a identificar con mayor precisión qué contextos favorecen la preservación lingüística y cuáles incrementan el riesgo de desaparición.

Anexos

Tablas auxiliares

Se incluyen las tablas generadas durante el análisis, necesarias para la preparación de las hipótesis:

`df_country_counts`:

Se crea esta tabla auxiliar que agrupa las lenguas por país y contabiliza cuántas lenguas en peligro tiene cada uno. Esta tabla se utilizó tanto para el cálculo del coeficiente de Pearson en la hipótesis **H4** como para su visualización posterior.

```
# dataset con número de lenguas en peligro por país
df_country_counts = df.groupby("Countries_list")["Name_English"].count().reset_index()
df_country_counts.rename(columns={"Name_English": "num_endangered_languages"}, inplace=True)
df_country_counts.head()
```

	Countries_list	# num_endangered_langu...
0	Afghanistan	21
1	Albania	3
2	Algeria	10
3	Angola	4
4	Argentina	16

5 rows x 2 cols 10 per page << < Page 1 of 1

```
df_final = df.merge(df_country_counts, on="Countries_list", how="left")
df_final.head()
```

Tabla de contingencia normalizada. Región y Grado de peligro de desaparición. H1:

	Vulnerable	Definitely endangered	Severely endangered	Critically endangered	Extinct
Region					
ASIA (EX. NEAR EAST)	0.297365	0.365119	0.126725	0.160602	0.050188
BALTICS	0.333333	0.444444	0.111111	0.000000	0.111111
C.W. OF IND. STATES	0.167568	0.378378	0.194595	0.113514	0.145946
EASTERN EUROPE	0.301887	0.415094	0.226415	0.000000	0.056604
LATIN AMER. & CARIB	0.344828	0.217868	0.180251	0.199060	0.057994
NEAR EAST	0.150943	0.358491	0.283019	0.075472	0.132075
NORTHERN AFRICA	0.185185	0.111111	0.259259	0.296296	0.148148
NORTHERN AMERICA	0.134948	0.148789	0.211073	0.325260	0.179931
OCEANIA	0.204403	0.169811	0.264151	0.286164	0.075472
SUB-SAHARAN AFRICA	0.140127	0.207006	0.245223	0.267516	0.140127
WESTERN EUROPE	0.186441	0.508475	0.211864	0.033898	0.059322

Diccionario de equivalencias de países

Para garantizar la correspondencia entre los nombres de países del dataset lingüístico y el dataset socioeconómico, se creó un diccionario de equivalencias:

```
# 5. Mapeo para que coincidan los nombres de los países en los dos datasets
mapeo = {
    "United States Of America": "United States",
    "Russian Federation": "Russia",
    "Bolivia (Plurinational State Of)": "Bolivia",
    "Venezuela (Bolivarian Republic Of)": "Venezuela",
    "Lao People'S Democratic Republic": "Laos",
    "Myanmar": "Burma",
    "Viet Nam": "Vietnam",
    "Iran (Islamic Republic Of)": "Iran",
    "New Caledonia (France)": "New Caledonia",
    "Micronesia (Federated States Of)": "Micronesia, Fed. St.",
    "United Kingdom Of Great Britain And Northern Ireland": "United Kingdom",
    "The Former Yugoslav Republic Of Macedonia": "Macedonia",
    "United Republic Of Tanzania": "Tanzania",
    "Syrian Arab Republic": "Syria",
    "Libyan Arab Jamahiriya": "Libya",
    "Democratic Republic Of The Congo": "Congo, Dem. Rep.",
    "Timor-Leste": "East Timor",
    "Central African Republic": "Central African Rep.",
    "French Polynesia (France)": "French Polynesia",
    "French Guiana (France)": "French Guiana",
    "Côte D'Ivoire": "Ivory Coast",
    "Greenland (Kingdom Of Denmark)": "Greenland",
    "Bosnia And Herzegovina": "Bosnia & Herzegovina",
    "Republic Of Moldova": "Moldova",
    "Congo": "Congo, Repub. Of The",
    "Republic Of Korea": "Korea, South",
    "Guam (U.S.A.)": "Guam",
}
```

Fuentes y bibliografía

Datasets

Lasso, F. (2018). Countries of the World [Dataset]. Kaggle.
<https://www.kaggle.com/datasets/fernandol/countries-of-the-world> (kaggle.com in Bing)

The Guardian. (2017). Extinct Languages [Dataset]. Kaggle.
<https://www.kaggle.com/datasets/the-guardian/extinct-languages> (kaggle.com in Bing)

Organismos internacionales

UNESCO Ad Hoc Expert Group on Endangered Languages. (2003). Language Vitality and Endangerment. UNESCO.

World Bank. (2024). Population density (people per sq. km of land area). World Development Indicators. <https://data.worldbank.org/indicator/EN.POP.DNST> (data.worldbank.org in Bing)

Artículos y recursos técnicos

Domínguez Noriega, I. (2026, 14 de febrero). Coeficiente de correlación de Spearman: Guía completa 2025. Estadísticamente. <https://estadisticamente.com/coeficiente-de-correlacion-de-spearman-guia-completa-2025/> (estadisticamente.com in Bing)

numiqo. (s.f.). Correlación de Spearman – Explicación sencilla. <https://numiqo.es/tutorial/spearman-correlation>